

# 气象因素对植物群落响应的时间序列建模研究

——基于加州区域多源遥感气象数据的 NDVI 预测分析

231820102 魏来

Github 项目地址: [lynx-coco/bigdata --- lynx-coco/bigdata](https://github.com/lynx-coco/bigdata)

**摘要** 在全球气候变化背景下，极端气象事件发生频率和强度显著增加，对区域植被生长与生态系统稳定性产生了深远影响。植被指数（NDVI）作为表征植被生长状况的重要遥感指标，其变化过程受到降水、温度及土壤水分等多种气象与环境因素的共同影响。如何整合多源时序数据，对多重条件下植被响应进行有效建模与预测，是当前生态环境建模中的重要问题。本文以美国加利福尼亚州为研究区域，基于 2016–2025 年的 MODIS NDVI、NOAA 气象数据（包括降水、最高温与最低温）以及 SMAP 土壤湿度数据，构建统一的 16 天时间尺度多源时间序列。在此基础上，分别采用传统时间序列模型 SARIMA、单步多变量 LSTM、多步 Seq2Seq LSTM 以及 Transformer 模型，对 NDVI 的未来变化趋势进行预测，并对模型性能进行系统对比。实验结果表明，SARIMA 模型难以有效刻画多变量驱动下的非线性植被响应过程，预测性能较差；LSTM 模型在单步预测中取得显著优于 SARIMA 的效果；Seq2Seq LSTM 在多步预测中保持了较好的稳定性；Transformer 模型在单步与多步预测中均取得最优表现。研究结果验证了深度学习方法在干旱条件下植被时序预测中的有效性，并为生态环境变化评估提供了有价值的技术参考。

**关键词：** NDVI；多源时间序列；LSTM；Transformer；植被响应

# 目录

1 引言 .....	3
2 研究问题与相关性分析 .....	3
2.1 问题界定 .....	3
2.2 相关性分析 .....	3
3 实验设计与模型方法 .....	4
3.1 实验总体流程 .....	4
3.2 预测任务设置与模型训练策略 .....	5
3.3 评价指标 .....	5
3.4 使用的预测模型 .....	5
4 实验过程与结果 .....	6
4.1 数据来源与处理 .....	6
4.2 单步预测结果分析 .....	6
4.3 多步预测结果分析 .....	7
4.4 Transformer 模型预测结果分析 .....	7
5 分析与讨论 .....	8
5.1 单步预测模型讨论 .....	8
5.2 多步预测模型讨论 .....	8
5.3 模型综合对比与讨论 .....	9
6 实验局限与改进方向 .....	9
7 结论与展望 .....	10
8 参考文献 .....	11

## 1 引言

气候变化导致的极端气象事件已成为全球性生态环境问题。极端降水与温度条件不仅直接影响植被的生理活动，还会通过改变土壤水分条件、蒸散过程和能量交换等机制，对生态系统产生长期影响。准确刻画近年来植被群落对气象与土壤湿度的动态响应，对于生态风险评估和资源管理具有重要意义。

传统植被变化分析多依赖统计方法或单变量时间序列模型，难以充分刻画多源环境因素之间的复杂耦合关系。随着遥感与气象观测技术的发展，大量高时间分辨率、多来源的数据得以获取，为构建基于深度学习的多变量时序预测模型提供了可能。

近年来，循环神经网络（RNN）及其变体 LSTM 等模型在时间序列预测领域表现突出；同时，基于注意力机制的 Transformer 模型在长序列建模中展现出更强的表达能力。本文尝试在统一的数据框架下，对传统方法与多种深度学习模型进行系统比较，以评估其在植被响应预测中的适用性。

## 2 研究问题与相关性分析

### 2.1 问题界定

本研究的核心任务是在统一的时间序列框架下，定量刻画地表植被动态对多源气象强迫的响应机制。植被指数（NDVI）的变化并非孤立的时间演变过程，而是受到降水、温度以及土壤水分等环境变量非线性耦合驱动的结果。在加利福尼亚州复杂的生态背景下，建立预测模型面临着三重挑战：首先是物理过程的非线性，环境变量在不同阈值下对植被生长的贡献具有显著差异；其次是生理响应的时滞性，植被对气象事件（如降水）的反馈往往存在周期的延迟；最后是长程依赖性，植被当下的生长状态受制于过去数月生态系统的累积效应。因此，本文将该问题界定为一种基于历史观测序列的多变量推断任务，即利用过去  $m$  个步长的环境变量时序，通过特征融合与动态建模，实现对未来  $H$  个步长内 NDVI 变化趋势的稳健预报。<sup>[1]</sup>

### 2.2 相关性分析

在建立预测模型之前，我们首先通过统计手段评估驱动因子与 NDVI 之间的内在关联，这不仅为特征选择提供了依据，也为模型回看窗口（Look-back Window）的设定提供了物理支持。在模型构建之前，对输入变量进行深入的关联性分析是理解系统物理逻辑的基础。

通过计算 Pearson 相关系数发现，土壤湿度（Soil Moisture）与 NDVI 之间存在显著的正相关关系，这从数据层面证实了在干旱与半干旱气候区，水分的可利用性是决定植被生长潜力的主导因子。

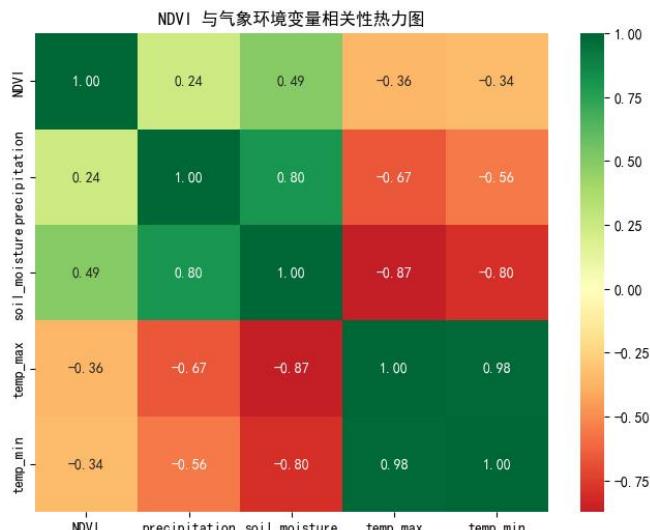


图 1 NDVI 与气象环境变量相关性热力图

相比之下，最高气温与 NDVI 的关联表现出复杂的季节性分异：在生长季初期，气温升高往往伴随着

NDVI 的上升，而在夏季极端高温阶段，由于蒸散发压力的激增，两者可能呈现负相关态势，这种热胁迫效应为后续模型捕获极端气象响应提供了特征基础。进一步的互相关分析揭示了植被响应在时间维度上的时滞效应（Time-lag Effect）。实验结果表明，降水量对 NDVI 的驱动作用在滞后 2 至 3 个采样周期（约 32-48 天）时达到峰值。

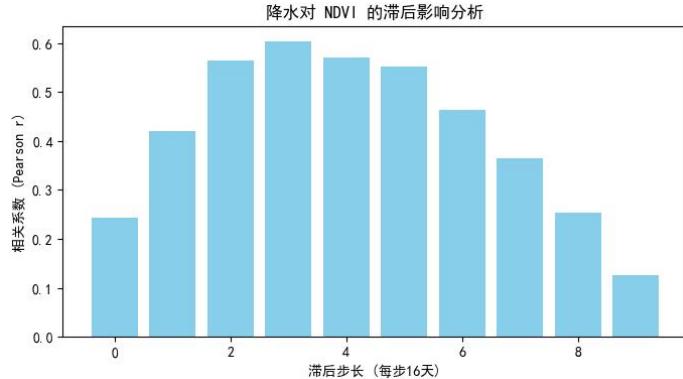


图 2 降水对 NDVI 的滞后影响分析

这一物理规律反映了水分从地表降落、入渗土壤到被根系吸收并体现为叶绿素增加的生物物理路径。这种时滞性的存在具有重要的模型指导意义，它直接论证了在本研究中引入具有长程记忆能力的深度学习架构（如 Transformer 的自注意力机制）的必要性。通过将观测窗口设置为覆盖这些关键时滞节点的长度，模型能够有效提取历史气象信号对未来植被状态的预测性贡献。此外，研究区域的物候演变曲线显示了极强的季节性循环模式。NDVI 通常在春季达到顶峰，随后随土壤水分的枯竭而回落，表现出与地中海气候高度一致的相位特征。这种显著的周期性不仅验证了数据源的可靠性，也要求预测模型必须具备强大的序列位置感知能力。通过上述相关性与时滞分析，本研究确立了多变量输入的特征配置方案，为后文模型结构的优化与预测任务的执行奠定了扎实的理论与数据支撑。

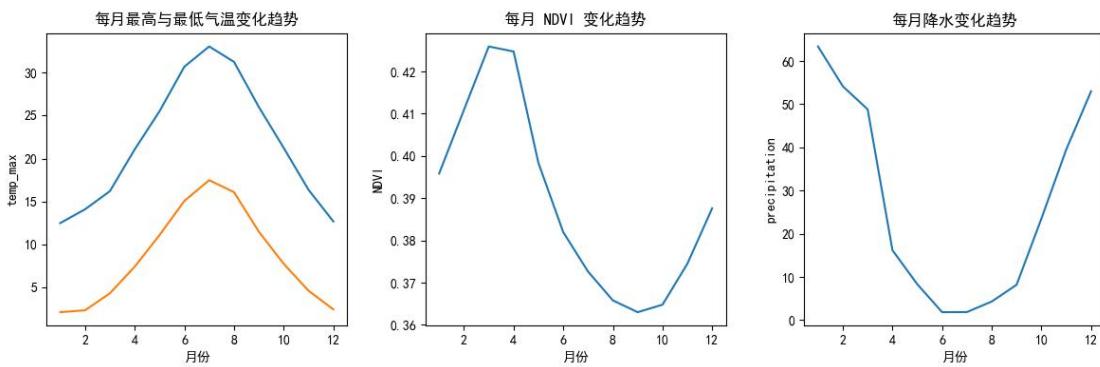


图 3 加州一年内每月降水、气温与 NDVI 变化趋势

### 3 实验设计与模型方法

#### 3.1 实验总体流程

本文围绕 NDVI 时间序列预测任务，设计了从数据预处理、模型训练到预测评估的完整实验流程。首先，基于多源遥感与气象数据构建对齐的多变量时间序列数据集，并按照时间顺序划分为训练集、验证集和测试集。随后，分别采用传统时间序列模型与深度学习模型进行建模与预测，并在统一的数据划分和评价标准下对模型性能进行对比分析。

在模型训练阶段，训练集用于模型参数学习，验证集用于超参数调节与早停策略的判断，测试集仅用于最终预测性能评估。所有模型均在相同的数据划分条件下进行实验，以保证不同方法之间的可比性。

### 3.2 预测任务设置与模型训练策略

为充分刻画 NDVI 的时间依赖特征，本文采用滑动时间窗口方式构建模型输入。具体而言，模型输入由过去若干个时间步内的多变量观测序列组成，输出为未来 NDVI 的预测结果。

针对不同预测需求，本文设计了单步预测与多步预测两类任务。在单步预测任务中，模型根据历史观测数据预测下一时间步的 NDVI 值，用于评估模型对短期变化的刻画能力；在多步预测任务中，模型一次性输出未来多个时间步的 NDVI 序列，用于分析模型在中期预测情形下的稳定性以及误差随预测步长增加的变化趋势。

在深度学习模型训练过程中，本文采用均方误差（MSE）作为损失函数，并使用 Adam 优化算法进行参数更新。为防止模型在训练过程中出现过拟合现象，引入基于验证集性能的早停策略，当验证集误差在若干轮训练中不再下降时终止训练，并保存验证性能最优的模型参数。

所有模型均在相同的硬件环境下运行，并在测试阶段关闭随机性因素，以确保预测结果的稳定性和可重复性。

### 3.3 评价指标

为全面评估不同模型在 NDVI 预测任务中的表现，本文选取多种常用回归评价指标对预测结果进行定量分析。具体包括平均绝对误差（MAE）、均方根误差（RMSE）以及决定系数（R<sup>2</sup>）。

其中，MAE 和 RMSE 用于衡量模型预测值与真实值之间的误差大小，反映预测精度水平；R<sup>2</sup> 用于衡量模型对 NDVI 变化趋势的拟合能力，其值越接近 1 表明模型对序列变化的解释能力越强。对于多步预测任务，本文进一步按预测步长分别计算各时间步的评价指标，以分析预测误差随时间推进的变化特征。

## 3.4 使用的预测模型

### 3.4.1 SARIMA 模型

SARIMA（Seasonal Autoregressive Integrated Moving Average）是一类经典的时间序列预测模型，通过引入季节差分和季节性自回归项来刻画时间序列中的周期性结构。该模型假设序列的变化主要由自身历史值及其线性组合所决定，适用于具有稳定季节模式的时间序列数据。

在本文中，SARIMA 模型仅以 NDVI 序列作为输入，不引入任何外生变量，用于建立单变量预测模型。其主要作用是作为基线方法，与后续基于深度学习的多变量模型进行对比，以评估复杂模型在非线性建模和多源信息融合方面的优势。

### 3.4.2 单步多变量 LSTM 模型

长短期记忆网络（Long Short-Term Memory，LSTM）<sup>[2]</sup>是一种能够有效建模长期依赖关系的循环神经网络结构，适合处理具有时间相关性的序列数据。相比传统时间序列模型，LSTM 能够刻画输入变量之间的非线性关系，并通过门控机制缓解梯度消失问题。

本文构建了单步多变量 LSTM 模型，以过去若干时间步内的多源环境变量序列作为输入，预测下一时间步的 NDVI 值。该模型重点关注短期预测性能，旨在评估多变量信息在 NDVI 预测中的作用，以及 LSTM 在单步预测场景下相对于传统模型的改进效果。

### 3.4.3 残差 Seq2Seq LSTM 模型

为进一步扩展预测任务至多步时间尺度，本文引入基于 Encoder–Decoder 架构的 Seq2Seq LSTM 模型。该模型首先通过 Encoder 对历史多变量时间序列进行编码，提取其整体时间依赖特征；随后由 Decoder 在编码结果的基础上逐步生成未来多个时间步的 NDVI 预测值。与单步预测模型相比，Seq2Seq 模型能够直接输出一段未来时间序列，从而更适合中期预测任务。通过该模型，可以分析预测步长增加对预测精度的影响，并评估误差随时间累积的变化特征。

### 3.4.4 Transformer 模型

Transformer 模型基于自注意力机制，通过显式建模时间序列中不同时间步之间的全局依赖关系，实现对序列特征的并行建模。相较于循环神经网络结构，Transformer 在长序列建模和多步预测任务中具有更高的灵活性和表达能力。<sup>[3]</sup>

本文构建了多变量 Transformer 模型，将 NDVI 及其对应的多源环境变量作为输入特征，分别开展单步和多步 NDVI 预测实验。通过与 LSTM 及 Seq2Seq 模型的对比分析，评估 Transformer 在多源时间序列预测任务中的性能表现及其对长期依赖关系的建模能力。

## 4 实验过程与结果

### 4.1 数据来源与处理

本文以美国加利福尼亚州为研究区域，选取 2016 年 1 月至 2025 年 12 月作为研究时间范围，综合使用多源遥感与气象数据构建 NDVI 时间序列预测数据集。所使用的数据包括植被指数、气象变量以及土壤湿度信息。

植被指数数据来自 NASA 发布的 MODIS MOD13A2 产品<sup>[1]</sup>，该产品提供 16 天合成的 NDVI 数据，空间分辨率为 1 km。本文通过 Google Earth Engine 平台<sup>[2]</sup>对研究区域内的 NDVI 数据进行空间均值聚合，从而获得能够表征区域整体植被变化特征的 NDVI 时间序列。气象数据采用 NOAA 提供 gridMET 数据集<sup>[3]</sup>，包括累计降水量、最高气温和最低气温。该数据集原始时间分辨率为日尺度格点数据，为与 NDVI 的时间尺度保持一致，本文按照 NDVI 的 16 天合成窗口对气象变量进行时间聚合，并对研究区域内数据进行空间平均处理。

此外，本文引入 NASA 的 SMAP SPL3SMP\_E 土壤湿度产品<sup>[4]</sup>，选取晨间表层土壤湿度作为研究变量。该数据同样通过 Google Earth Engine 平台获取，并在每个 16 天时间窗口内计算区域平均值，同时记录窗口内的有效观测天数，以反映土壤湿度数据在不同时段的可用情况。

由于 MODIS NDVI 数据采用固定的 16 天合成周期，本文以 NDVI 的时间戳作为统一时间基准，对来自不同来源、不同时间分辨率的数据进行对齐处理。NOAA 气象数据和 SMAP 土壤湿度数据均按照 NDVI 的 16 天时间窗口进行聚合，从而在时间维度上保持一致。通过上述处理过程，本文构建了统一的多源时间序列数据结构。在每一个时间步中，数据均包含 NDVI 值以及对应时间窗口内的累计降水量、土壤湿度、最高气温和最低气温等特征。最终构建的数据集共包含 227 个时间步，覆盖近十年的植被与气象变化过程。

在模型训练与评估阶段，本文按照时间顺序对数据集进行划分，其中训练集、验证集和测试集的比例约为 7:1.5:1.5。所有输入变量均采用 Min-Max 方法进行归一化处理，以消除不同变量量纲和数值范围差异对模型训练的影响，模型预测结果在评估阶段再进行反归一化，以保证误差指标的可解释性。

### 4.2 单步预测结果分析

首先，采用 SARIMA 模型对 NDVI 时间序列进行单变量预测，以作为传统时间序列方法的基线结果。实验结果表明，SARIMA 模型在测试集上的预测误差较大，其 MAE 为 0.0232，RMSE 为 0.0321，决定系数 R<sup>2</sup> 为 -0.318，说明该模型难以有效刻画 NDVI 的变化趋势，预测效果甚至劣于简单均值模型。这一结果表明，在多源环境因素共同驱动的情形下，仅依赖 NDVI 自身历史信息的线性模型存在明显局限。

在引入多源环境变量后，单步多变量 LSTM 模型的预测性能得到显著提升。该模型在测试集上的 MAE 降至 0.0144，RMSE 降至 0.0231，R<sup>2</sup> 提升至 0.308，表明模型能够较好地拟合 NDVI 的季节变化趋势。尽管在部分峰值和突变点处仍存在一定程度的平滑现象，但整体预测精度和趋势拟合能力明显优于 SARIMA 模型。



图 4 单步多变量 LSTM 模型预测曲线对比

#### 4.3 多步预测结果分析

在多步预测任务中，本文采用 Seq2Seq LSTM 模型对未来连续三个时间步的 NDVI 进行预测。整体结果显示，该模型在多步预测中的总体 MAE 为 0.0148，RMSE 为 0.0208， $R^2$  为 0.7245，表明模型在中期预测任务中仍保持了较为稳定的预测性能。

进一步从分步预测结果来看，随着预测步长的增加，预测误差呈现逐步上升趋势。第一步预测的  $R^2$  为 0.383，第二步下降至 0.322，第三步进一步下降至 0.209。这一结果体现了多步时间序列预测中常见的误差累积效应，也反映了远期预测不确定性逐步增强的特点。

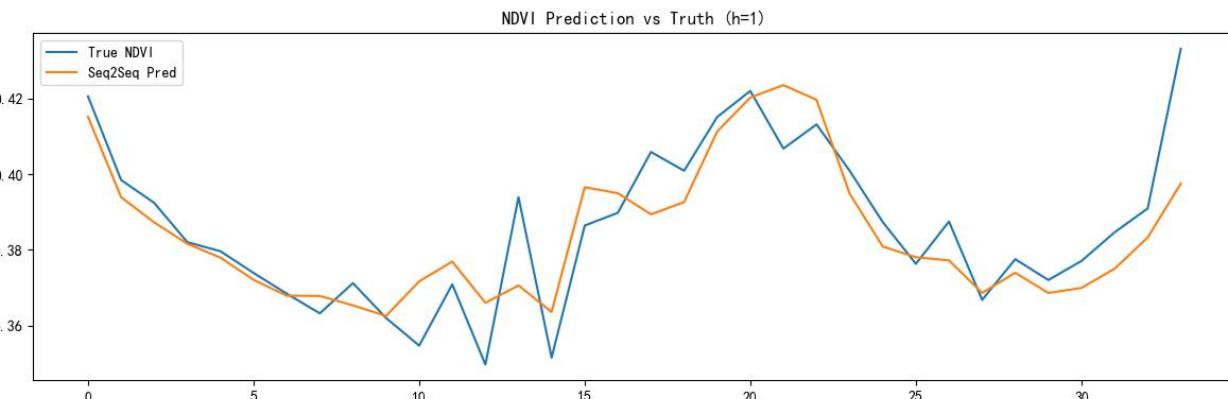


图 5 残差 Seq2Seq LSTM 模型预测曲线对比

#### 4.4 Transformer 模型预测结果分析

在进一步引入 Transformer 模型后，实验结果显示其在 NDVI 多步预测任务中取得了最优性能。Transformer 模型在第一步预测中的  $R^2$  达到 0.737，MAE 降至 0.0073，显著优于 LSTM 系列模型，表明其在短期预测中具有较高精度。

在多步预测情形下，Transformer 模型的性能同样随着预测步长增加而有所下降，但整体表现仍优于 Seq2Seq LSTM 模型。第二步和第三步预测的  $R^2$  分别为 0.450 和 0.383，对应的 MAE 分别为 0.0118 和 0.0141，显示出 Transformer 在捕捉 NDVI 长期依赖关系和季节性结构方面的优势。

综合来看，Transformer 模型在短期和中期预测任务中均表现出更强的泛化能力，尤其在处理复杂非线性关系和长时间依赖方面优于传统循环神经网络结构。

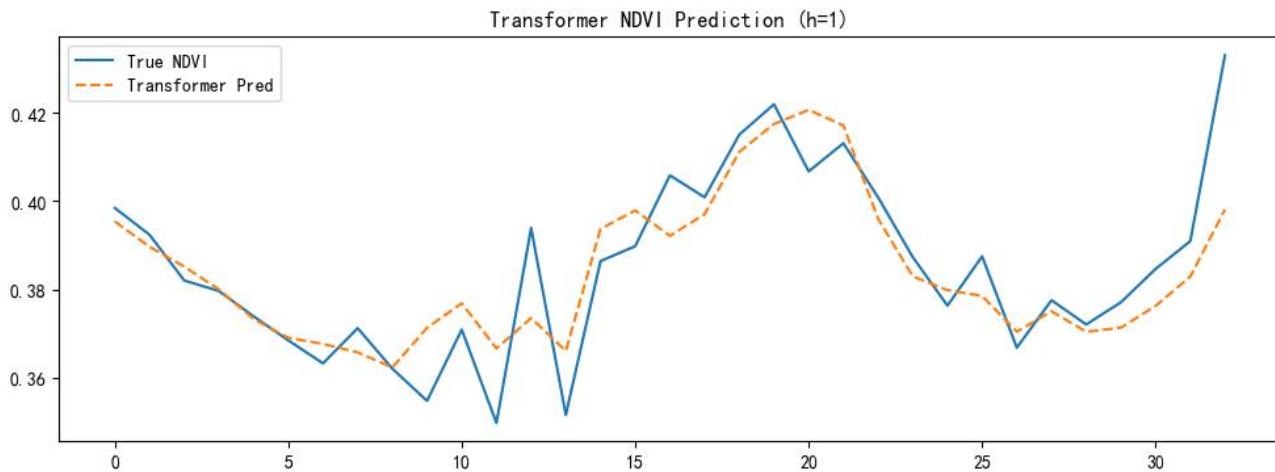


图 6 Transformer 模型预测曲线对比

## 5 分析与讨论

模型	预测方式	MAE	RMSE	R <sup>2</sup>
SARIMA	单步	0.0232	0.0321	-0.3179
LSTM	单步	0.0144	0.0231	0.3082
Seq2Seq LSTM	多步（整体）	0.0148	0.0208	0.7245
Transformer	多步 (h=1)	0.0073	0.0107	0.7368
Transformer	多步 (h=2)	0.0118	0.0158	0.4501
Transformer	多步 (h=3)	0.0141	0.0210	0.3827

表 1 不同模型在 NDVI 预测任务中的性能对比

### 5.1 单步预测模型讨论

首先，以 SARIMA 模型作为传统时间序列预测方法，对 NDVI 序列进行单变量预测。实验结果表明，SARIMA 模型在测试集上的预测性能较弱，其 MAE 和 RMSE 分别为 0.0232 和 0.0321，决定系数 R<sup>2</sup> 为负值 (-0.3179)。

负 R<sup>2</sup> 结果表明，SARIMA 模型对 NDVI 时间序列的预测效果甚至劣于简单的均值预测方法。这一现象说明，仅依赖 NDVI 自身历史信息的线性模型难以有效刻画植被变化过程中存在的非线性特征和复杂动态关系，尤其是在长期尺度和多源环境因素共同作用的情况下，其预测能力存在明显局限。

在引入多源环境变量后，单步多变量 LSTM 模型的预测性能得到显著提升。实验结果显示，该模型在测试集上的 MAE 和 RMSE 分别下降至 0.0144 和 0.0231，R<sup>2</sup> 提升至 0.3082。

相较于 SARIMA 模型，LSTM 模型能够有效利用降水、气温和土壤湿度等外生变量的信息，通过非线性映射关系捕捉环境条件与 NDVI 变化之间的复杂依赖结构。这一结果表明，多变量输入和深度学习模型在 NDVI 预测任务中具有明显优势，尤其在短期预测情形下能够更准确地刻画植被变化趋势。

### 5.2 多步预测模型讨论

为进一步分析模型在中期预测任务中的表现，本文采用基于 Encoder-Decoder 结构的 Seq2Seq LSTM 模型进行多步 NDVI 预测。整体预测结果表明，Seq2Seq 模型在多步预测任务中仍保持了较为稳定的预测性能，其总体 MAE 为 0.0140，RMSE 为 0.0209，h=1 时 R<sup>2</sup> 为 0.7245。

从分步预测结果来看，随着预测步长的增加，模型误差呈现逐步上升趋势。具体而言，第一步预测的

$R^2$  达到 0.7245，第二步下降至 0.3218，第三步进一步下降至 0.1994。这一现象反映了多步预测中误差逐步累积的普遍规律，也说明模型在远期预测中不确定性显著增加。

尽管如此，Seq2Seq 模型在多步预测场景下仍明显优于传统方法，表明 Encoder–Decoder 结构在建模 NDVI 中期变化趋势方面具有一定优势。

在进一步引入 Transformer 模型后，实验结果显示其在 NDVI 多步预测任务中取得了当前实验条件下的最优性能。Transformer 模型在第一步预测中的  $R^2$  达到 0.7368，显著高于 LSTM 系列模型，同时 MAE 降至 0.0075，表明其在短期预测中具有极高的精度。

在多步预测情形下，Transformer 模型的性能同样随着预测步长增加而有所下降，但整体表现仍优于 Seq2Seq LSTM 模型。第二步和第三步预测的  $R^2$  分别为 0.4501 和 0.3827，显示出 Transformer 在捕捉长期依赖关系方面的优势。

该结果说明，自注意力机制能够更有效地整合历史时间步中的关键信息，从而提升 NDVI 时间序列预测的整体性能，尤其在短期预测和复杂依赖关系建模方面表现突出。

### 5.3 模型综合对比与讨论

综合各模型的实验结果可以发现，模型预测性能整体呈现出从传统方法到深度学习方法逐步提升的趋势。SARIMA 模型由于其线性假设和单变量输入限制，在 NDVI 预测任务中表现最弱；单步多变量 LSTM 模型在引入外生变量后显著提升了预测精度；Seq2Seq LSTM 模型在多步预测任务中保持了较好的稳定性；而 Transformer 模型在整体预测性能上表现最佳，尤其在短期预测场景中优势明显。

此外，实验结果还表明，多步预测任务中不可避免地存在误差累积现象，不同模型在预测步长增加时的性能下降程度存在差异。这一现象为模型选择和应用场景提供了重要参考，即在短期预测任务中优先考虑高精度模型，而在中期预测任务中需要在预测步长与稳定性之间进行权衡。

实验结果表明，多源环境变量对植被指数变化具有显著影响，深度学习模型能够有效整合这些信息。传统 SARIMA 模型由于假设线性与平稳性，难以适应复杂的生态过程。LSTM 在单步预测中具有良好表现，而 Seq2Seq 结构为多步预测提供了可行方案。Transformer 凭借注意力机制，在长期依赖建模方面展现出明显优势。

需要指出的是，NDVI 本身存在遥感噪声与季节合成效应，且研究区域采用空间均值可能掩盖局地差异，未来可进一步引入空间维度或更高分辨率数据。

## 6 实验局限与改进方向

尽管本文基于多源遥感与气象数据，构建了统一时间尺度的 NDVI 多变量时间序列数据集，并系统比较了 SARIMA、LSTM、Seq2Seq LSTM 和 Transformer 等多种模型在 NDVI 预测任务中的表现，但仍存在一定局限性，有待在后续研究中进一步改进。

首先，在数据层面，本文对研究区域内的遥感与气象数据采用空间均值聚合的方式进行处理，将原本具有空间分辨率的信息简化为区域尺度的一维时间序列。该方法有助于降低建模复杂度，但同时忽略了区域内部不同地形、土地覆盖类型及局地气候条件所带来的空间差异，可能掩盖局部植被变化特征。

其次，在时间分辨率方面，由于 MODIS NDVI 数据采用固定的 16 天合成周期，本文所有外生变量均需对齐至该时间尺度。这在一定程度上限制了模型对短期气象波动的响应能力，使预测结果更侧重于中低频变化趋势。再次，在多步预测任务中，随着预测步长的增加，各类模型均表现出不同程度的误差累积现象，远期预测的不确定性明显上升。尽管 Transformer 模型在多步预测中整体表现优于 LSTM 系列模型，但仍难以完全避免预测精度随时间推进而下降的问题。

此外，本文所使用的输入变量主要包括降水、气温和土壤湿度，尚未纳入太阳辐射、蒸散量、植被类型或人类活动等潜在影响因素，变量选择的简化可能对模型预测性能和泛化能力产生一定限制。

针对上述问题，未来研究可从多个方向进行改进。一方面，可引入空间维度，构建时空联合预测模型，以更全面地刻画植被变化特征；另一方面，可进一步拓展外生变量类型，并结合特征重要性分析方法，提高模型的解释能力和应用价值。

## 7 结论与展望

本文以美国加利福尼亚州为研究区域，基于 2016—2025 年的 MODIS NDVI、NOAA 气象数据和 SMAP 土壤湿度数据，构建了统一时间尺度的多源时间序列数据集，并系统比较了传统时间序列模型与多种深度学习模型在 NDVI 预测任务中的表现。

实验结果表明，传统 SARIMA 模型难以有效刻画多源气象因子驱动下 NDVI 的非线性变化过程；引入多变量输入后，LSTM 模型在单步预测任务中显著提升了预测精度；Seq2Seq LSTM 模型在多步预测中表现出较好的稳定性；Transformer 模型凭借自注意力机制，在单步和多步预测任务中均取得最优预测性能，显示出其在建模长期依赖关系方面的优势。

研究结果表明，多源气象与环境变量的融合以及深度学习模型的引入，对于提升 NDVI 时间序列预测精度具有显著作用。本文的研究为区域尺度植被变化监测和预测提供了一种可行的技术框架，也为后续开展更高时空分辨率、更强解释能力的植被建模研究奠定了基础。

## 8 参考文献

- [1] **Piao, S., et al.** (2020). Plant phenology and global climate change: Current progresses and challenges. *Global Change Biology*, 25(6), 1922-1940.
- [2] **Hochreiter, S., & Schmidhuber, J.** (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.
- [3] **Vaswani, A., et al.** (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30.
- [4] **Didan, K.** (2021). MOD13A2 MODIS/Terra Vegetation Indices 16-Day L3 Global 1km SIN Grid V061 [Data set]. NASA EOSDIS Land Processes DAAC. <https://doi.org/10.5067/MODIS/MOD13A2.061>
- [5] **Gorelick, N., et al.** (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202, 18-27.
- [6] **Abatzoglou, J. T.** (2013). Development of gridded surface meteorological data for ecological forecasting and modeling. *International Journal of Climatology*, 33(5), 1211-1224.
- [7] **Entekhabi, D., et al.** (2010). The Soil Moisture Active Passive (SMAP) Mission. *Proceedings of the IEEE*, 98(5), 704-716.